

Universidad del Rosario

MATEMÁTICAS APLICADAS Y CIENCIAS DE LA COMPUTACIÓN

INGENIERIA DE DATOS

Miguel Salamanca, Juan Simbaqueba, Camila Pataroyo

Proyecto Final

November 19, 2022

TABLA DE CONTENIDO

1	Pro	blemática	1			
2	Dise 2.1 2.2	eño Diseño Conceptual(Diagrama entidad relación)	1 1 2			
3	Nor	rmalización Reglas para 1NF	3			
	3.2	Regla para 2NF	3			
	3.3	Reglas para 3NF	4			
4	Inse	erción Datos	4			
5	Consultas					
	5.1	Consulta 1 - Información de los clubes	6			
	5.2	Consulta 2 - Información de los jugadores	7			
	5.3	Consulta 3 - Información de las estadisticas de cada uno de los				
		jugadores	7			
	5.4	Consulta 4 - Los 13 máximos goleadores del torneo	8			
	5.5	Consulta 5 - Los 13 máximos asistidores del torneo	9			
	5.6	Consulta 6 - Los colores característicos de cada club	10			
	5.7	Consulta 7 - Presupuesto disponible para cada uno de los direc-				
		tores tecnicos	10			
	5.8	Consulta 8 - Jugadores más influyentes	11			
6	Visualización					
	6.1	Goleadores	11			
	6.2	Asistidores	12			
	6.3	Presupuesto director tecnico	12			
7	Ana	álisis	12			
8	Cor	nlusión	13			

1 Problemática

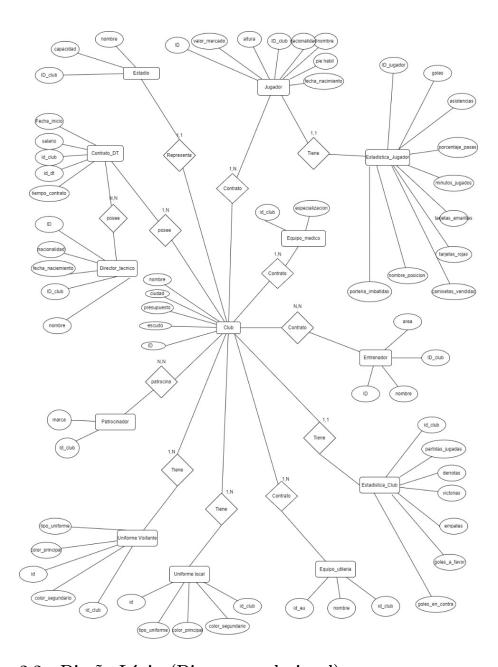
Esta propuesta busca facilitar la búsqueda de información por parte de los usuarios que necesiten o quieran por su propia cuenta, obtener datos acerca de su liga de preferencia. Hoy en día hay muchos usuarios dentro del mundo del futbol que quisieran obtener una gran cantidad de datos para realizar un buen análisis sobre su equipo o sobre algún jugador, ya sea solo para adquirir conocimiento o para algún otro tema que incluya un objetivo monetario para esta persona, como lo es el mundo de las apuestas, o también si se necesitan sacar datos para los mismos funcionarios del club para manejar el tema de las finanzas e igualmente para los funcionarios de las propias ligas. En cuanto al mundo de las apuestas, existen muchas personas que basan su economía en esta actividad, ya sea por parte de las casas de apuestas como también de sus usuarios, el hecho de tener una base de datos que contenga cada estadística del club y sus jugadores permitirá una mejor predicción y facilitara el hecho de sacar un indicador de multiplicación para las apuestas de cada partido. Como segunda problemática a superar, actualmente cada equipo de futbol mueve mucho dinero fuera de sus partidos, la realización de esta propuesta busca facilitar para los usuarios la búsqueda de cualquier producto que quieran adquirir que esté relacionado con el club, ya sean sus camisetas, sus sudaderas, sus equipaciones, o también las boletas de los partidos, sin tener que salir del lugar donde encuentran las estadísticas y resultados del club. Todo al alcance de un clic desde la comodidad ya sea de su celular, computador o tableta.

2 Diseño

En las siguientes dos subsecciones se encuentran los modelos de datos que definen como se modela la estructura lógica y conceptual de la base de datos de la liga de futbol colombiana. Estos modelos son entidades importantes para introducir la abstracción en una base de datos, como se conectan entre sí, como se procesan y almacenan dentro del sistema. También ayudan a evitar la redundancia de datos porque se implementar la normalización 3NF.

2.1 Diseño Conceptual(Diagrama entidad relación)

En el modelo conceptual fue diseñado en la plataforma ERDPlus, el modelo de datos identifica las relaciones de más alto nivel entre las diferentes entidades. Incluye las entidades importantes y las relaciones entre ellas, como lo son club, jugador, estadísticas jugador, estadísticas club, entrenador, director técnico entre otras.



2.2 Diseño Lógico(Diagrama relacional)

En el modelo de datos lógico fue diseñado en PGModeler, el modelo describe los datos con el mayor detalle posible, independientemente de cómo se implementarán físicamente en la base de datos. Incluye todas las tablas y atributos que se relacionan entre ellos, cada atributo está especificado con su tipo y en

caso particular de ser llave primaria o llave foránea.

3 Normalización

Para la edición del plano inicial de las tablas tuvimos en cuenta la normalización 3NF que se estructura de la siguiente forma:

Reglas para 1NF 3.1

- 1. Cada registro debe ser único, sin filas duplicadas
- 2. Cada celda debe contener un valor, debe verificar que no existan atributos multivalor

Todo nuestro modelo ya estaba normalizado en 1NF, por lo cual no tuvi- mos que hacer nunguna modificaci on en este aspecto, ya que cumplia las condiciones.

3.2 Regla para 2NF

- 1. Debe satisfacer 1NF
- 2. Si la clave principal (PK) de una tabla consta de uno y solo una columna, automáticamente satisface 2NF
- 3. Si hay una clave principal compuesta, cada columna no clave debe depender de toda la llave. Se deben eliminar dependencias paciales de la llave.

Existian unas tablas en nuestro modelo que no tenian llave primaria como la tabla estadisticas club, lo cual resolvimos creando el atributi id estadisticas club porque los demas atributos no eran los apropiados para ser llave primaria de esta tabla.



3.3 Reglas para 3NF

- 1. Satisfacer 2NF
- 2. Sin dependencias transitivas: Las columnas no claves (que no forman parte de la PK), no pueden depender de otras columnas que tampoco sean no clave.

En nuestro caso en especifico incialmente teniamos una tabla llamada uniforme con los siquientes atributos: id club, tipo de uniforme, color primario, color secundario

Note que hay una dependencia transitiva entre los colores, el tipo y el id del club , ya que un club tiene dos tipos de uniformes y varios colores pueden ser de muchos clubs y tipos de uniforme. Por lo que decidimos crear dos tablas, uniforme visitante y uniforme local el cual solucional el problema de transitividad.



4 Inserción Datos

Web scraping, es una técnica utilizada mediante Python para extraer información de sitios web, en nuestro caso en específico extrajimos los datos de TransferMarket. El web scraping está muy relacionado con la indexación de la web, la cual indexa la información de la web utilizando la librería requests,

se enfoca más en la transformación de datos sin estructura en la web (como el formato HTML) en datos estructurados que pueden ser almacenados y analizados en la base de datos liga, en una archivo CSV. El uso que le dimos a esta herramienta fue la extracción de los datos de las tablas principales y con mayor cantidad de datos que era muy complicado e ineficiente extraerlos a mano ya que gracias a su capacidad de generar grandes cantidades de datos para crear contenidos de calidad pudimos extraer con éxito todos los datos para poder hacer un mayor análisis.

Luego de extraer los datos continuamos con la insercción de ellos mediante la siguiente imagen, la cual leia archivos csv donde se almacenaban gran cantidad de datos.

```
COPY PUBLIC.club(id_cl,nombre,ciudad,presupuesto_en_miles,id_estadio)
FROM 'C:\Users\Laboratorios EICT\Documents\Liga\club.csv'

DELIMITER ';'
CSV HEADER;

COPY PUBLIC.estadio(capacidad,nombre,id_es)
FROM 'C:\Users\Laboratorios EICT\Documents\Liga\estadio.csv'

DELIMITER ';'
CSV HEADER;

COPY PUBLIC.entrenador(nombre,id_e,area,id_club)
FROM 'C:\Users\Laboratorios EICT\Documents\Liga\entrenador.csv'

DELIMITER ';'
CSV HEADER;

COPY PUBLIC.entrenador(nombre,id_e,area,id_club)
FROM 'C:\Users\Laboratorios EICT\Documents\Liga\entrenador.csv'

DELIMITER ';'
CSV HEADER;
```

5 Consultas

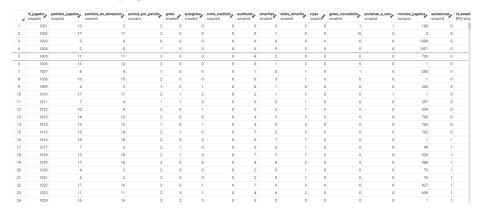
5.1 Consulta 1 - Información de los clubes

4	id_cl [PK] smallint	nombre character varying (30)	ciudad character varying (30)	presupuesto_en_miles, smallint	id_estadio smallint
1	101	Junior de Barranquilla	Barranquilla	2413	200
2	102	Atletico Nacional	Medellin	2238	201
3	103	Deportes Tolima	Ibague	2148	202
4	104	Millonarios FC	Bogota	1910	203
5	105	CD America de Cali	Cali	1505	204
6	106	Independiente Medellin	Medellin	1503	205
7	107	Deportivo Cali	Cali	147	206
8	108	Independiente Santa Fe	Bogota	1450	207
9	109	Once Caldas	Manizales	1055	208
10	110	Alianza Petrolera	Barrancabermeja	96	209
11	111	CD La Equidad Seguros SA	Bogota	93	210
12	112	Atletico Bucaramanga	Bucaranga	895	211
13	113	Aguilas Doradas	Rionegro	86	212
14	114	Deportivo Pereira	Pereira	818	213
15	115	Jaguares de Cordoba	Cordoba	773	214
16	116	Asociacion Deportivo Pasto	Pasto	753	215
17	117	Envigado FC	Envigado	67	216
18	118	Boyaca Patriotas FC	Boyaca	610	217
19	119	Cortulua	Tulua	593	218
20	120	AD Union Magdalena	Santa Marta	455	219

5.2 Consulta 2 - Información de los jugadores



5.3 Consulta 3 - Información de las estadisticas de cada uno de los jugadores.

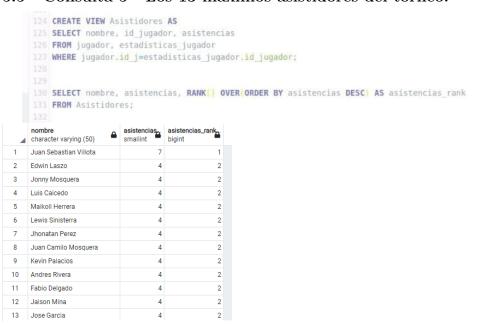


5.4 Consulta 4 - Los 13 máximos goleadores del torneo.

	16 CREATE VIEW Goleadores AS					
	17 SELECT nombre, id jugador, goles					
	118 FROM jugador, estadísticas_jugador					
	<pre>119 WHERE jugador.id_j=estadisticas_jugador.id_jugador;</pre>					
	20					
	121 SELECT nombre	1 SELECT nombre, goles, RANK()				
	22 FROM Goleadores; demo					
	122					
4	nombre character varying (50)	goles smallint	goles_rank bigint			
1	Luis Carlos Ruiz	10	1			
2	Luciano Pons	9	2			
3	Leonardo Castro	9	2			
4	Miguel Borja	8	4			
5	Duvier Riascos	8	4			
6	Dayro Moreno	8	4			
7	Wilson Morelo	8	4			
8	Andres Renteria	6	8			
9	Diego Herazo	5	9			
10	Mender Garcia	5	9			
11	Adrian Ramos	5	9			
12	Michael Rangel	5				
13	Luis Gonzalez	5	9			
13	Luis Gorizalez	3	9			

Se crea una vista llamada Goleadores con el producto cartesiano entre las tablas jugador y estadísticas jugador, donde la llave foránea es id jugador . En la vista se puede ver los atributos nombre, id jugador y goles. Luego se hace un Rank y order by de los mejores goleadores de todos los clubs, es decir los jugadores que hallan hecho más goles y se ordena de forma decreciente. Gracias a la consulta podemos ver que el mejor goleador de todoa los clubs es Luis Carlos Ruiz con el cual cuanta con 10 goles.

5.5 Consulta 5 - Los 13 máximos asistidores del torneo.



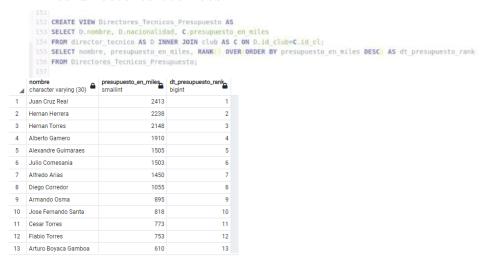
Se creó una vista llamada Asistidores con el producto cartesiano entre las tablas jugador y estadísticas jugador , donde la llave foránea es id jugador. En la vista se selecciona los atributos nombre, id jugador y asistencias .Luego se hace un Rank y order by de las mejores asistencias de todos los clubs, es decir los jugadores que hallan hecho más asistencias y se ordena de forma decreciente. Gracias a la consulta podemos ver que la mejor asistencia es de Juan Sebastián Villota con 7 asistencias y los siguientes 12 jugadores que siguen ocupan el segundo lugar en el ranking con 4 asistencias.

5.6 Consulta 6 - Los colores característicos de cada club.



Creamos un inner join entre las tablas club y uniforme local, donde la llave foránea es club id. Esta consulta nos permite ver el nombre del club y los colores principales y secundarios del uniforme local de cada club de la liga.

5.7 Consulta 7 - Presupuesto disponible para cada uno de los directores tecnicos.



Creamos una vista llamada Directores técnicos presupuesto en donde se creaba un inner join entre las tablas director técnico y club con llave foránea en el atributo id club. La vista nos permite ver el nombre, nacionalidad y presupuesto en miles de cada director técnico, luego haciendo un Rank y order by pudimos obtener el ranking del los directores técnicos que tienen mejores presupuestos , cómo lo es Juan Cruz Real con un presupuesto de 2413, Hernan Herrera con 2238 y Hernán Torres con 2148.

5.8 Consulta 8 - Jugadores más influyentes.

	4	nombre character varying (50)	puntos_por_partidon	influyentes_rank
	1	Carlos Arboleda	158	1
	2	Javier Lopez	99	2
	3	Cristian Arrieta	81	3
	4	Juan Sebastian Villota	76	4
	5	Mauricio Gomez	67	5
	6	Juan Pablo Nieto	61	6
	7	Cesar Quintero	60	7
	8	George Saunders	56	8
	9	Deivy Balanta	50	9
	10	Diego Gomez	48	10
	11	Feiver Mercado	47	11
	12	Jairo Ditta	46	12
	13	Juan Camilo Mosquera	45	13
	14	Jose Garcia	44	14
	15	Rodrigo Paillalef	43	15
	16	Duvan Viafara	42	16
	17	Manuel Arias	41	17
	18	Juan Nazarit	40	18
	19	Jacobo Escobar	39	19
	20	Camilo Charris	38	20
	21	Jose Guzman	37	21
	22	Adam Ozeri	36	22
	23	Arley Mosquera	35	23
	24	Luis Hurtado	34	24
CREA	TE VI	EW Jugadores_influy	entes AS	

```
SELECT nombre, id_jugador, puntos_por_partido

FROM jugador, estadisticas_jugador

WHERE jugador.id_j=estadisticas_jugador.id_jugador;

SELECT nombre, puntos_por_partido, RANK() OVER(ORDER BY puntos_por_partido DESC) AS Influyentes_rank

FROM Jugadores_influyentes;
```

Creamos una vista llamada jugadores influyentes en donde se hace un producto cartesiano entre las tablas jugador y estadoisticas jugador, donde la llave foranea es id jugador y se selecciona los atributos nombre, id y puntos por partido de cada uno de los jugadores. Adicinalmente se creo un rank y orden by para que se seleccionaran los jugadores mas influyentes de todos los clubs.

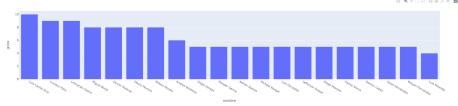
6 Visualización

Las siguientes visualizaciones fueron creadas con Dash y con las consultas de la sección anterior

6.1 Goleadores

Consulta 1, ranking de los mejores goleadores de todos los clubs de la liga colombiana de fútbol.

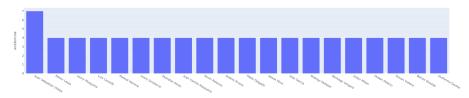
Tabla goleadores



6.2 Asistidores

Consulta 2, ranking de los mejores asistidores de todos los clubs de la liga colombiana de fútbol.

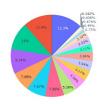
Tabla asistidores



6.3 Presupuesto director tecnico

Consulta 7,que muestra el presupuesto disponible de cada uno de los directores tencicos en grafica de torta.

Tabla presupuesto tecnicos





7 Análisis

Identificando las características de cada análisis desarrollado, mencionaremos las ventajas y desventajas de cada visualización.

La primera de las gráficas, la del pastel de presupuestos técnicos tiene la ventaja de contar con una representación visual muy clara, pudiendo entender de forma muy directa la relación de los valores, y su diferencia con respecto a otros. Pero con la desventaja de que, al tener varios datos de números muy pequeños, estos no tienen su representación, y se terminan perdiendo, sin saber

a qué jugador representa.

Por otra parte, la segunda y tercera en grafica tienen la ventaja de poseer todos los datos, pero con la desventaja de ocupar bastante espacio, además de poder verse feos en caso de gran variedad de datos.

Sirve en caso de tener pocos datos, ya que en caso de una gran cantidad se extendería horizontalmente donde resultaría imposible ver bien los datos. A diferencia de la grafica por pastel, donde da algo igual que tantos datos haya.

8 Conlusión

Usamos una excelente fuente de datos llamada TransferMarket la cual se actualiza bastante seguido, con mucha información del mundo del futból y de manera organizada, por lo que nos ayudo a hacer una base de datos grande en cuanto a tablas y datos.

El diseño en la base de datos presento cierta complejidad, al necesitar realizar varios cambios mientras se realizaba, pero una vez todo estuvo establecido en un papel, se pudo ordenar de una mejor forma cuando se paso a los modelos relacionales, facilitándonos el entendimiento y terminar de despejar varias dudas que había.

Presentamos bastates inconvenientes con la inserción de datos , ya que la Liga de fútbol de Colombia cuenta con muchisimos datos, inicialmente creimos que podiamos ingresarlos a mano pero tuvimos que buscar otra forma más eficiente la cual fue Web scraping.

Sobre la conexión de base de datos, hubo ciertos problemas respecto al código en Python, pero nada serio, el tener apuntes de clase con el código de otro ejemplo facilito demasiado. Y ligado a eso, una vez con la conexión establecida, el desarrollo usando Dash tuvo cierta facilidad, teniendo ya básicamente todas las herramientas preparadas y solo necesitando realizar algunos cuantos cambios

Fue un proyecto que nos gasto mucho tiempo en la estruturación de la base de datos, en la búsqueda e inserción de datos, en la conexión de Python y demás obejetivos que teniamos por la cantidad de tablas y datos. Fue un reto para nosotros que pudimos resolver de la mejor forma usando diferentes herramientas y aprendiendo muchas cosas más.

13